

Pytorch 입문 부트캠프

3. Pytorch Exercises (1) Regression Task

목차


- 1 What is Regression?
- 2 Linear Regression
- 3 Regression with Neural Network

1

What is Regression?

Regression Task

- Regression 이란? (Remind)
 - Input 변수(x)를 통해 연속형 변수인 output (y, label, 종속변수)을 예측하는 모델링 기법
 - 연속형 변수의 예측이기 때문에 예측값 $\leftrightarrow$ 실제값의 차이를 통해 모델 성능 평가



Regression Task

- 사용할 Dataset : 보스턴 주택 가격 데이터, 총 Data Size = 506개 (506, 14)

컬럼	의미
[01] CRIM	자치시(town) 별 1인당 범죄율
[02] ZN	25,000 평방피트를 초과하는 거주지역의 비율 ↓
[03] INDUS	비소매상업지역이 점유하고 있는 토지의 비율 ↓
[04] CHAS	찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0)
[05] NOX	10ppm 당 농축 일산화질소 ↓
[06] RM	주택 1가구당 평균 방의 개수 ↑
[07] AGE	1940년 이전에 건축된 소유주택의 비율 ↓
[08] DIS	5개의 보스턴 직업센터까지의 접근성 지수 ↑
[09] RAD	방사형 도로까지의 접근성 지수 ↑
[10] TAX	10,000 달러 당 재산세율 ↑
[11] PTRATIO	자치시(town)별 학생/교사 비율 ↑
[12] B	$1000(B_k - 0.63)^2$, 여기서 B_k 는 자치시별 흑인의 비율을 말함.
[13] LSTAT	모집단의 하위계층의 비율(%) ↓
[14] MEDV	본인 소유의 주택가격(중앙값) (단위: \$1,000)

)(

Y


Regression Task

- 모델링 목표

- 13개의 input 변수들로 MEDV(주택가격)을 예측
- 새로운 input 이 생겼을 때, 실제 output 값과 최대한 가까운 예측

- 모델 성능 평가

- 전체 데이터 셋(506개)를 7:3, 8:2 등의 비율로 trainset, testset으로 분리 (랜덤)
- Trainset 만으로 모델 학습 후 test set의 input X로 예측값을 계산, test set의 실제 output 과 예측값과의 차이(RMSE 등)를 측정하여 모델 평가



Train set
(학습에만 사용)

Test set
(평가에만 사용)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

2


Linear Regression

Linear Regression

- 선형 회귀 모델은?

- $Y = \alpha + \beta x$ 꼴로 input x 로 y 를 설명하는 모형.

- x 에 여러 개의 변수(=다중회귀)가 사용되기도 하며 x 들이 선형 결합으로 이루어져 있어서 선형 회귀 모형





$$\hat{y} = 2.03 + 0.89x$$

회귀 계수

Linear Regression

- 선형 회귀 모델의 학습(=회귀 계수의 추정법) : 최소 제곱법
 - 예측값과 실제값의 차이가 최소가 되도록 만드는 Regression line을 찾는 것
 - 그때의 절편과 기울기를 회귀 계수라고 하고, **최소 제곱법**이라는 방법으로 추정한다.



$$\hat{y} = ax + b \text{ 일 때,}$$

최소화 하고자 하는 목표 :

$$\sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$

최소화 하려는 방식은
Least Square Estimation으로,
Gradient Descent와는 조금 다름,

Linear Regression

- 다중 선형 회귀 모델 ($\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$) 의 예시,

Output / Label

Input / Feature

구매	앱 오픈	상품 조회	검색	카테고리 조회	장바구니
2,713	121,808	289,578	79,245	50,552	11,112
3,937	143,859	353,002	95,162	64,056	13,796
3,892	139,798	312,916	87,196	54,354	12,028
3,846	133,569	305,703	80,255	55,028	11,531
4,453	139,119	319,664	80,273	55,337	11,994
4,387	159,408	375,097	94,199	63,655	13,703
3,405	148,440	346,754	87,149	60,979	12,859
2,801	148,015	349,770	87,165	63,554	12,321
4,104	175,023	435,184	113,969	81,585	16,357
4,652	159,787	390,849	96,701	69,969	14,202

- 추정된 회귀 모델 : 구매 = $24.38 + 0.0139 \times \text{앱오픈} - 0.01 \times \text{상품조회} + 0.01445 \times \text{검색}$
 $+ 0.0364 \times \text{카테고리조회} + 0.129 \times \text{장바구니}$

- 모델 해석 : (나머지 변수들이 고정일 때) 앱오픈이 1 늘어나면, 구매는 0.0139만큼 늘어난다.

Linear Regression

- Dummy 변수
 - Input 변수(x)들 중에 범주형 변수를 처리하기 위한 방법

[04] CHAS | 찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0)

- One-hot Encoding을 통해 처리해줌 (Dummy 변수)

id	color
1	red
2	blue
3	green
4	blue



id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0

0.7×2

0.5×2


0.3×1

3

Regression with **FC Layers**

Regression with Neural Network

- 2-Depth FC layers



- Linear Regression 모델과의 비교

	Linear Regression	2 Layers Neural Network
Parameter 수	14개 (절편 + 회귀계수)	91개 $(13 \times 6 + 6) + (6 + 1)$
최적화 방식	Least Square Estimation	Gradient Descent
선형모델	O	X (ReLU라는 비선형 함수 포함)

Regression with Neural Network

- 모델 학습 과정
 - `Torch.utils.data.datasets` 이용하여 데이터셋 구성
 - 모델 선언 /
 - Optimizer 선언 (Adam)
 - Trainset으로 학습 (data sample 1개씩 처리 vs Batch 처리)

실습 해볼까요?